减少RAG系统的压力

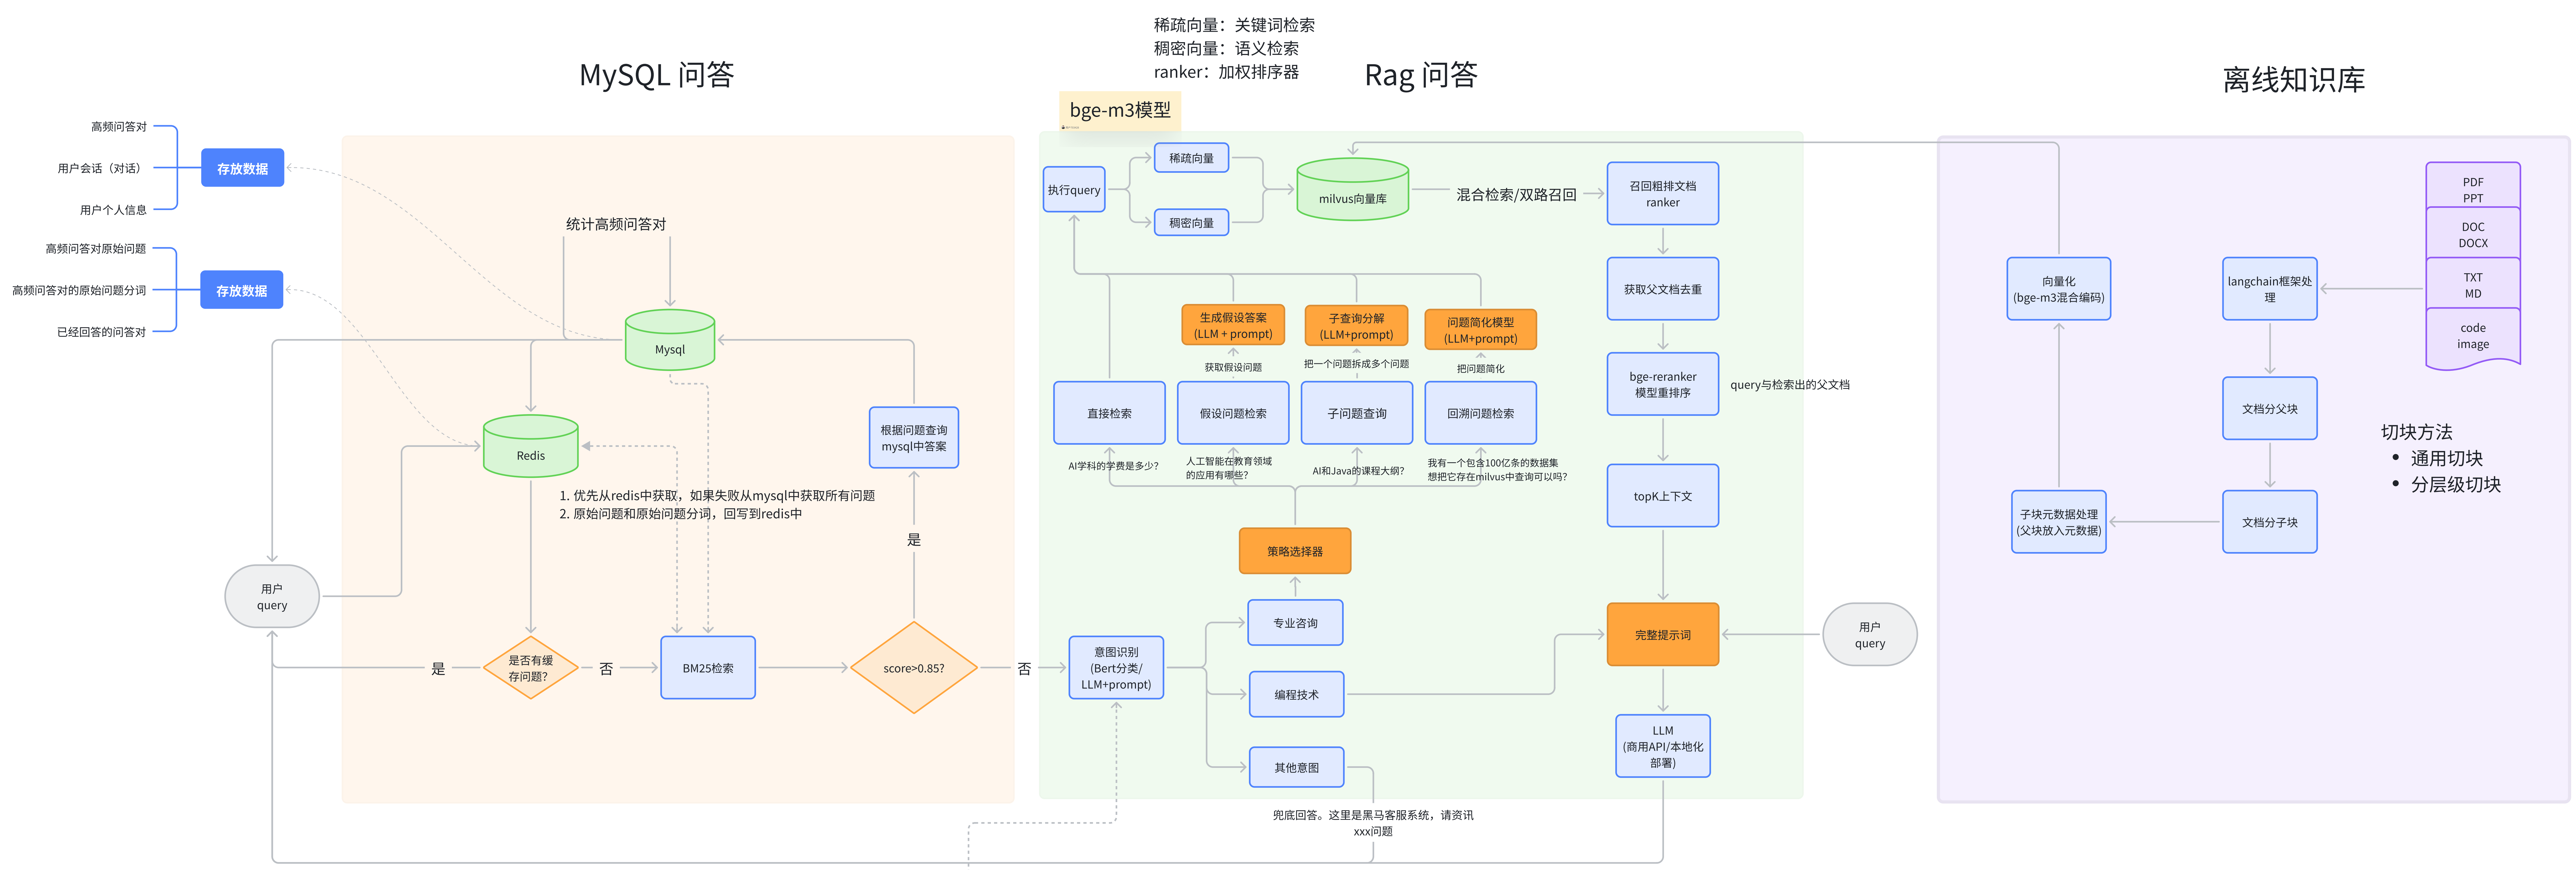

MySQL 问答

- 存放数据
  - 高频问答对
  - 用户会话（对话）
  - 用户个人信息
- 存放数据
  - 高频问答对原始问题
  - 高频问答对的原始问题分词
  - 已经回答的问答对

统计高频问答对

Mysql

Redis

1. 优先从redis中获取，如果失败从mysql中获取所有问题
2. 原始问题和原始问题分词，回写到redis中

根据问题查询mysql中答案

是

用户 query

是

是否有缓存问题?

否

BM25检索

score>0.85?

否

Rag 问答

稀疏向量：关键词检索
稠密向量：语义检索
ranker：加权排序器

bge-m3模型

执行query

稀疏向量

稠密向量

milvus向量库

混合检索/双路召回

召回粗排文档 ranker

获取父文档去重

bge-reranker 模型重排序

query与检索出的父文档

topK上下文

完整提示词

用户 query

LLM (商用API/本地化部署)

生成假设答案 (LLM + prompt)

获取假设问题

子查询分解 (LLM+prompt)

把一个问题拆成多个问题

问题简化模型 (LLM+prompt)

把问题简化

直接检索

AI学科的学费是多少?

假设问题检索

人工智能在教育领域的应用有哪些?

子问题查询

AI和Java的课程大纲?

回溯问题检索

我有一个包含100亿条的数据集想把它存在milvus中查询可以吗?

策略选择器

意图识别 (Bert分类/LLM+prompt)

专业咨询

编程技术

其他意图

兜底回答。这里是黑马客服系统，请资讯xxx问题

离线知识库

PDF PPT

DOC DOCX

TXT MD

code image

langchain框架处理

文档分父块

文档分子块

子块元数据处理 (父块放入元数据)

向量化 (bge-m3混合编码)

切块方法
- 通用切块
- 分层级切块

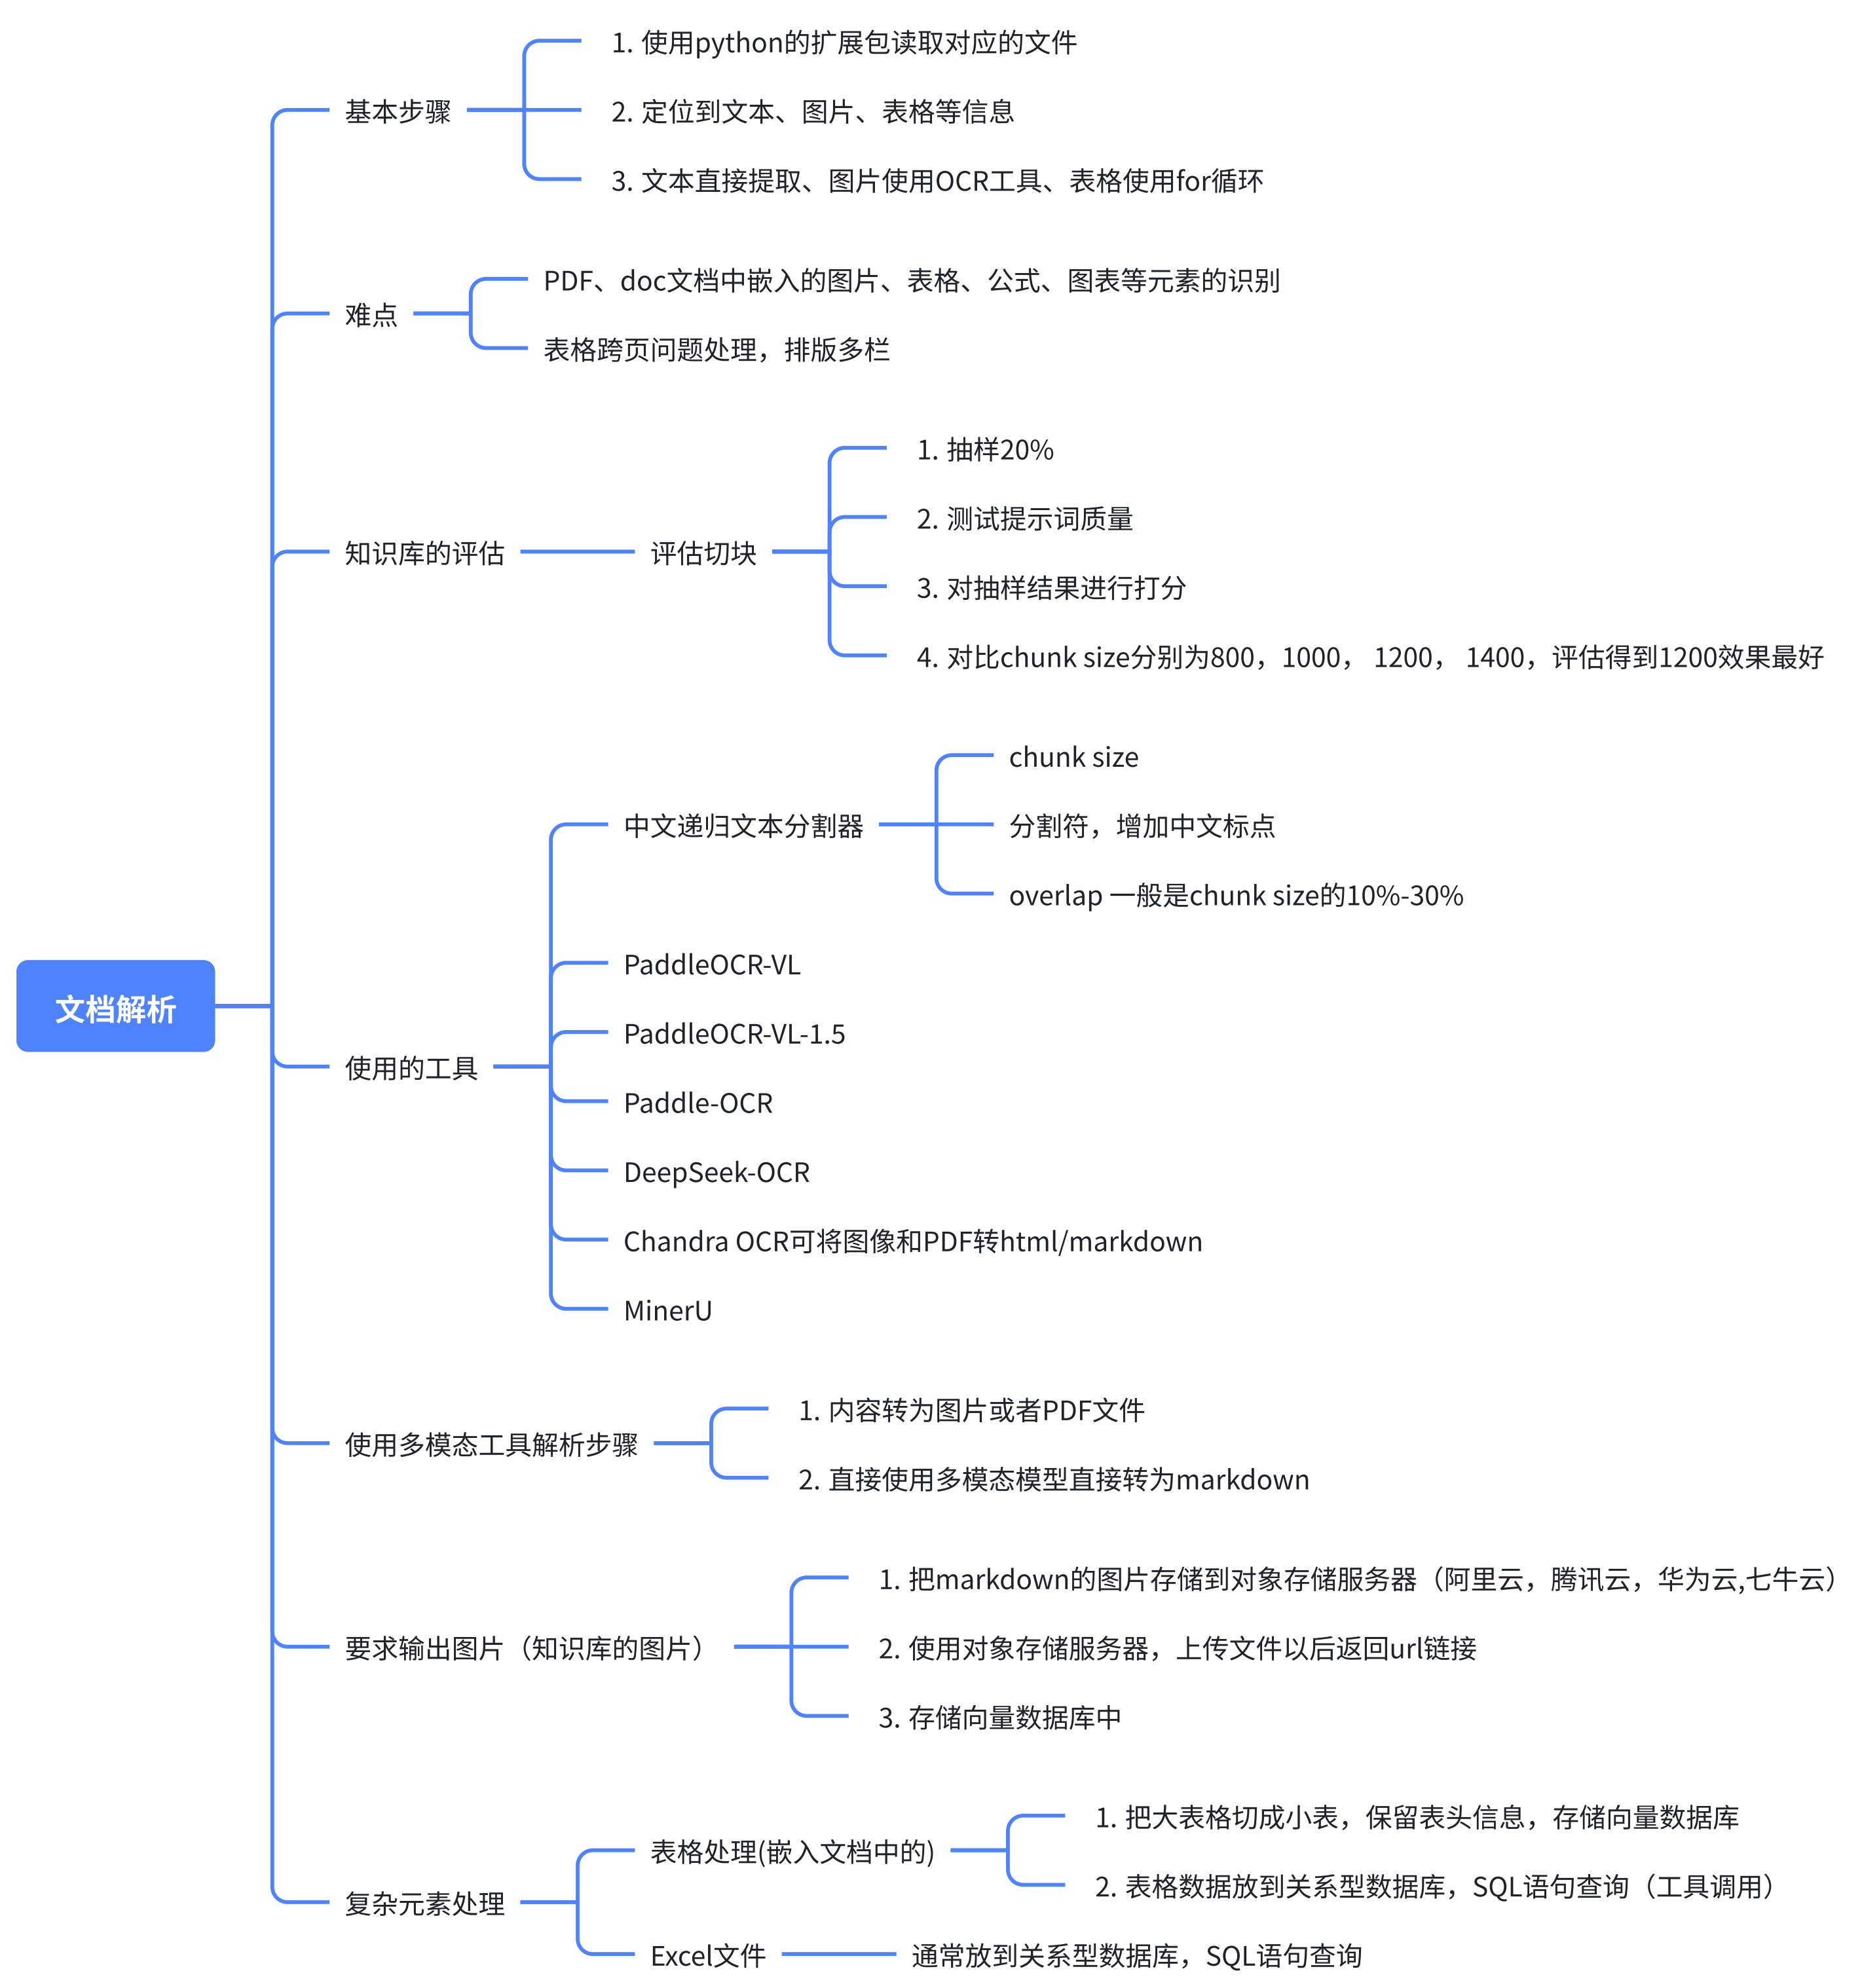

文档解析

- 基本步骤
  - 1. 使用python的扩展包读取对应的文件
  - 2. 定位到文本、图片、表格等信息
  - 3. 文本直接提取、图片使用OCR工具、表格使用for循环
- 难点
  - PDF、doc文档中嵌入的图片、表格、公式、图表等元素的识别
  - 表格跨页问题处理，排版多栏
- 知识库的评估
  - 评估切块
    - 1. 抽样20%
    - 2. 测试提示词质量
    - 3. 对抽样结果进行打分
    - 4. 对比chunk size分别为800，1000， 1200， 1400，评估得到1200效果最好
- 使用的工具
  - 中文递归文本分割器
    - chunk size
    - 分割符，增加中文标点
    - overlap 一般是chunk size的10%-30%
  - PaddleOCR-VL
  - PaddleOCR-VL-1.5
  - Paddle-OCR
  - DeepSeek-OCR
  - Chandra OCR可将图像和PDF转html/markdown
  - MinerU
- 使用多模态工具解析步骤
  - 1. 内容转为图片或者PDF文件
  - 2. 直接使用多模态模型直接转为markdown
- 要求输出图片（知识库的图片）
  - 1. 把markdown的图片存储到对象存储服务器（阿里云，腾讯云，华为云,七牛云）
  - 2. 使用对象存储服务器，上传文件以后返回url链接
  - 3. 存储向量数据库中
- 复杂元素处理
  - 表格处理(嵌入文档中的)
    - 1. 把大表格切成小表，保留表头信息，存储向量数据库
    - 2. 表格数据放到关系型数据库，SQL语句查询（工具调用）
  - Excel文件
    - 通常放到关系型数据库，SQL语句查询

BM25优化：直接使用语义向量（text-embedding），可以存储到milvus
数据库
redis优化：可以不用redis缓存

目的：检查当前的问题是否需求查询知识库

评估指标至少写两个

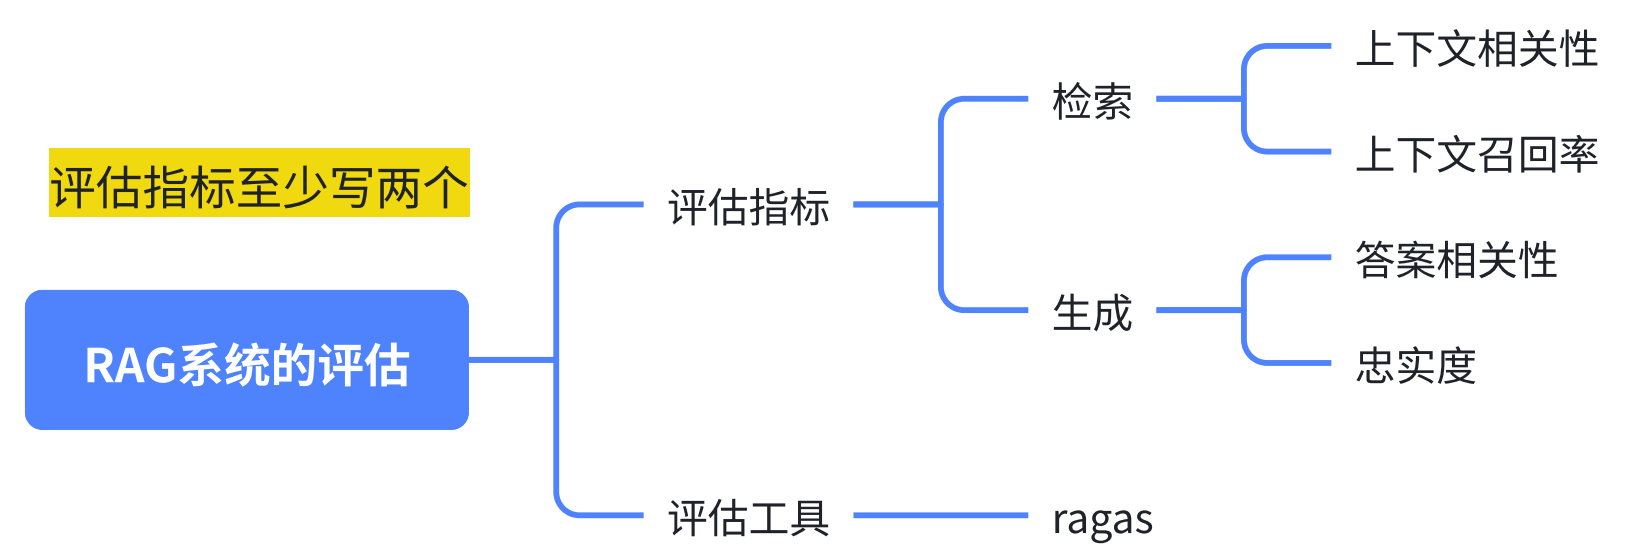

RAG系统的评估

- 评估指标
  - 检索
    - 上下文相关性
    - 上下文召回率
  - 生成
    - 答案相关性
    - 忠实度
- 评估工具
  - ragas

意图识别优化：
- bert优化掌握好，可以写bert分类
- 掌握不好，写提示词+大模型

query改写优化：
- 至少写3-4个，熟悉的
- 每类策略准备好例子

项目中涉及到多个提示词，一定要清楚提示词的思路

意图分类使用大模型或者Bert分类，优缺点
- LLM分类
  - 优点：实现简单，更新分类标签容易；
  - 缺点：响应时间长；存在幻觉；提升并发困难；
- Bert分类
  - 优点：响应时间快，稳定可控，没有幻觉。方便提升并发；
  - 缺点：研发成本高，不容易扩展分类；只能处理短文本；